Analiza porównawcza wskaźnika morderstw w Stanach Zjednoczonych

Hanna Kostecka Oliwia Orzeł

1 Wstęp

Celem niniejszego raportu jest przeprowadzenie analizy porównawczej danych rzeczywistych dotyczących przestępczości w Stanach Zjednoczonych. Wykorzystano zbiór danych *USArrests*, zawierający informacje o liczbie aresztowań za wybrane przestępstwa w 50 stanach USA w roku 1973.

Analizie poddano zmienną *Murder*, czyli liczbę aresztowań za morderstwa na 100 000 mieszkańców.

Dane podzielono na dwa zbiory:

- stany o niskiej urbanizacji, czyli *UrbanPop* mniejsze lub równe 65 procent,
- stany o wysokiej urbanizacji, czyli *UrbanPop* większe niż 65 procent.

Celem analizy jest porównanie poziomu przestępczości oraz zmienności danych między tymi grupami.

Dane pochodzą ze zbioru *USArrests*, dostępnego w repozytorium Rdatasets: `https://vincentarelbundock.github.io/Rdatasets/datasets.html`

2 Analiza rozkładu przy pomocy metryk statystycznych

2.1 Metody statystyczne

W celu przeprowadzenia analizy wykorzystano następujące miary statystyczne. Dla każdej z nich zaprezentowano odpowiedni wzór matematyczny.

Miary położenia

Miary te informują o przeciętnym poziomie wartości badanej cechy w zbiorze.

Średnia arytmetyczna ($\bar{x}$):

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Mediana (Me): Wartość środkowa uporządkowanego zbioru danych. Dla próby o liczebności n:

$$Me = \begin{cases} x_{\frac{n+1}{2}} & \text{dla } n \text{ nieparzystych} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2} & \text{dla } n \text{ parzystych} \end{cases}$$

Miary zmienności (rozproszenia)

Miary te określają stopień zróżnicowania danych wokół miar położenia.

Wariancja (s^2):

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Odchylenie standardowe (s):

$$s = \sqrt{s^2}$$

Rozstęp (R): Różnica między wartością największą a najmniejszą w zbiorze.

$$R = x_{\max} - x_{\min}$$

Rozstęp międzykwartylowy (IQR): Różnica między trzecim a pierwszym kwartylem, mierząca rozproszenie środkowych 50% obserwacji.

$$IQR = Q_3 - Q_1$$

Współczynnik zmienności (V): Względna miara zróżnicowania danych, wyrażana w procentach.

$$V = \frac{s}{\bar{x}} \cdot 100\%$$

Miary kształtu rozkładu

Służą do oceny asymetrii oraz spłaszczenia rozkładu badanej cechy.

Skośność (A): Miara asymetrii rozkładu. Wartości dodatnie oznaczają asymetrię prawostronną, a ujemne lewostronną.

$$A = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^3}{s^3}$$

Kurtoza (K): Miara spłaszczenia (ekscesu) rozkładu. Dodatnia wartość oznacza rozkład bardziej wysmukły, a ujemna bardziej spłaszczony niż rozkład normalny.

$$K = \frac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^4}{s^4} - 3$$

2.2 Wyniki obliczeń

Tabela 1: Statystyki opisowe zmiennej *Murder*

Miara	Niska urbanizacja	Wysoka urbanizacja
Liczba obserwacji	22	28
Średnia	7.73	7.83
Mediana	7.00	7.35
Minimum	0.80	2.60
Pierwszy kwartyl	2.90	4.78
Trzeci kwartyl	12.25	11.15
Maksimum	17.40	15.40
Rozstęp	16.60	12.80
IQR	9.35	6.38
Odchylenie standardowe	5.07	3.79
Wariancja	25.75	14.39
Współczynnik zmienności	65.63%	48.44%
Skośność	0.40	0.42
Kurtoza	-1.04	-0.80

2.3 Interpretacja wyników

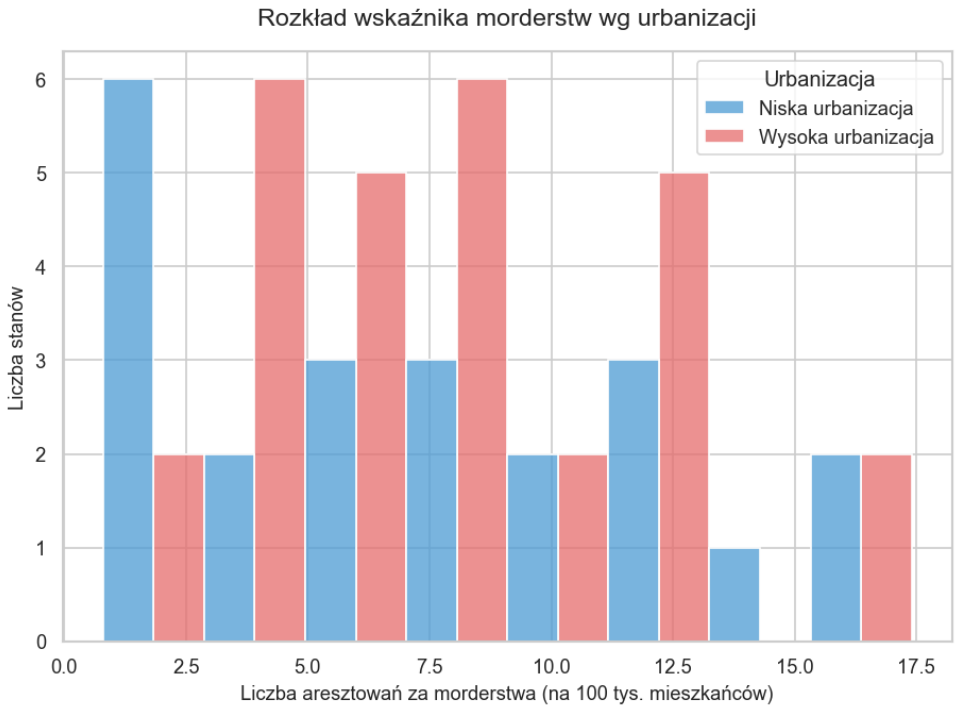
Analiza miar położenia: W stanach o wysokiej urbanizacji średnia wartość wskaźnika morderstw (7.83) oraz mediana (7.35) znajdują się na bardzo zbliżonym poziomie co w stanach o niskiej urbanizacji (średnia 7.73, mediana 7.00). Wskazuje to, że przeciętny poziom przestępczości w obu grupach jest niemal identyczny, niezależnie od stopnia urbanizacji. Warto zauważyć, że w obu grupach średnia jest wyższa od mediany, co jest pierwszym sygnałem występowania asymetrii prawostronnej w rozkładzie danych.

Analiza miar zmienności: Odchylenie standardowe (5.07 wobec 3.79) oraz rozstęp międzykwartylowy (9.35 wobec 6.38) pokazują, że to w stanach o niskiej urbanizacji występuje znacznie większe bezwzględne zróżnicowanie wskaźnika morderstw. Grupa stanów słabiej zurbanizowanych jest o wiele mniej jednorodna – znajdują się tam zarówno stany o absolutnie najniższym (minimum 0.80), jak i najwyższym (maksimum 17.40) odsetku morderstw z całego zestawienia. Potwierdza to również współczynnik zmienności, który dla stanów o niskiej urbanizacji jest wyraźnie wyższy (65.63%) niż dla stanów silnie zurbanizowanych (48.44%). Oznacza to, że stany słabiej zurbanizowane charakteryzują się dużo większą względną zmiennością badanego zjawiska.

Analiza miar kształtu rozkładu: Dodatnia skośność w obu grupach (0.40 dla niskiej i 0.42 dla wysokiej urbanizacji) potwierdza umiarkowaną asymetrię prawostronną. Oznacza to, że w obu badanych zbiorach przeważają stany o wskaźniku morderstw poniżej wartości średniej, a podwyższona średnia jest wynikiem występowania w próbie stanów o wysokich wskaźnikach przestępczości. Ujemna kurtoza (-1.04 dla niskiej i -0.80 dla wysokiej urbanizacji) wskazuje na to, że rozkłady są spłaszczone. Są one mniej wysmukłe niż rozkład normalny, co oznacza, że wartości badanej zmiennej nie są silnie skoncentrowane wokół średniej, lecz wykazują tendencję do rozproszenia na skrajach (szczególnie silnego w przypadku stanów o niskiej urbanizacji).

3 Prezentacja rozkładów na wykresach

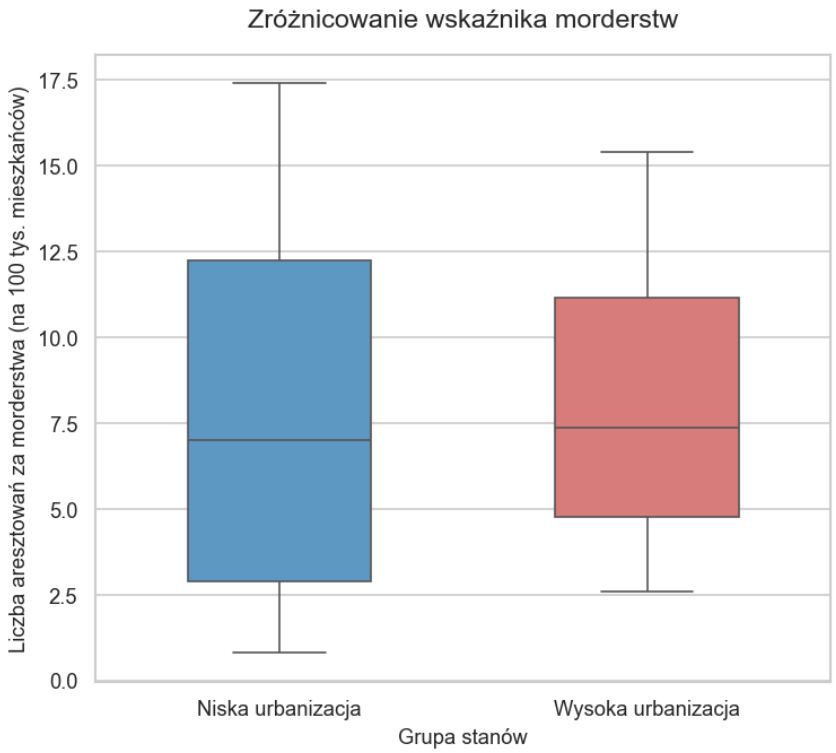
3.1 Histogram



Rysunek 1: Histogram zmiennej *Murder* dla dwóch grup urbanizacji

Histogram pozwala na wizualną ocenę rozkładu zmiennej *Murder*. Dzięki zestawieniu słupków obok siebie wyraźnie widać różnice między obiema grupami. Wbrew pierwotnym założeniom, to rozkład dla stanów o **niskiej urbanizacji** (kolor niebieski) jest znacznie bardziej "rozciągnięty- obejmuje zarówno wartości skrajnie niskie, jak i te absolutnie najwyższe na osi. Z kolei dane dla stanów o **wysokiej urbanizacji** (kolor czerwony) są zdecydowanie bardziej zwarte i silniej skoncentrowane wokół średniej. Zgodnie z wyliczeniami, oba rozkłady wykazują asymetrię prawostronną, co objawia się "ogonami"ciągnącymi się w stronę wyższych wartości wskaźnika.

3.2 Wykres pudełkowy



Rysunek 2: Wykres pudełkowy zmiennej *Murder* według poziomu urbanizacji

Wykres pudełkowy (ang. *boxplot*) doskonale obrazuje rzeczywiste zróżnicowanie badanej zmiennej. Widać na nim wyraźnie, że to w grupie stanów o **niskiej urbanizacji** (kolor niebieski) "pudełko", reprezentujące rozstęp międzykwartylowy (środkowe 50% obserwacji), jest zauważalnie dłuższe. Świadczy to o dużo większym rozproszeniu wskaźnika morderstw w tej grupie. Co więcej, górny "wąs"dla niskiej urbanizacji sięga znacznie wyżej, co oznacza, że to właśnie w tej grupie znajduje się stan o najwyższym odsetku morderstw w zestawieniu. Mimo tak dużych różnic w rozproszeniu, pozioma linia oznaczająca medianę znajduje się w obu grupach na bardzo zbliżonym poziomie.

4 Podsumowanie

Przeprowadzona analiza na podstawie poprawnych danych statystycznych rzuca nowe światło na różnice między stanami o niskim i wysokim poziomie urbanizacji.

Najważniejsze wnioski:

- przeciętny wskaźnik morderstw (zarówno średnia, jak i mediana) znajduje się na bardzo zbliżonym poziomie w obu badanych grupach,
- to stany o **niskiej urbanizacji** charakteryzują się znacznie większym rozproszeniem wyników, co widać między innymi po wyższym odchyleniu standardowym oraz szerszym rozstępie międzykwartylowym,
- w grupie o niskiej urbanizacji występują najbardziej skrajne wartości wskaźnika – zarówno absolutne minimum, jak i maksimum z całego zestawienia,

- rozkłady w obu grupach są prawostronnie skośne, co wskazuje na to, że w większości stanów wskaźnik jest niższy niż wynosi średnia, a podwyższają ją pojedyncze stany o bardzo wysokiej przestępczości,
- analiza ma charakter opisowy i nie pozwala jednoznacznie stwierdzić zależności przyczynowo-skutkowej, wskazuje jedynie na różnice w kształtowaniu się rozkładów.

Na podstawie uzyskanych wyników można stwierdzić, że poziom urbanizacji w Stanach Zjednoczonych nie determinuje jednoznacznie wyższego, przeciętnego wskaźnika morderstw, ale ma zauważalny związek z jego zmiennością i przewidywalnością.